

6.6 数据库有 5 个事务。设 $\min_sup = 60\%$, $\min_conf = 80\%$

273

TID	购买的商品
T100	{M, O, N, K, E, Y}
T200	{D, O, N, K, E, Y}
T300	{M, A, K, E}
T400	{M, U, C, K, Y}
T500	{C, O, O, K, I, E}

① frequent-item
② 强关联规则

A, C, D, Z, K
M, N, O, U, Y

(a) 分别使用 Apriori 算法和 FP-growth 算法找出频繁项集。比较两种挖掘过程的有效性。

(b) 列举所有与下面的元规则匹配的强关联规则 (给出支持度 s 和置信度 c)，其中， X 是代表顾客的变量， $item_i$ 是表示项的变量 (如 "A", "B" 等)：

$\forall x \in transaction, buys(X, item_1) \wedge buys(X, item_2) \Rightarrow buys(X, item_3) [s, c]$

PLABC
PLAB

解: (1) ① Apriori 算法

项集	support
{A}	20%
{C}	40%
{D}	20%
Z	80%
U	20%
K	100%
M	60%
N	40%
O	60%
U	20%
Y	60%

项集: L1, L2, L3... Lm 均有频繁项集, 全部写 C_r

项集	support
Z	80%
K	100%
M	60%
O	60%
Y	60%

项集	support
Z, K	80%
Z, M	40%
Z, O	60%
Z, Y	40%
K, M	60%
K, O	60%
K, Y	60%
M, O	20%
M, Y	40%
O, Y	40%

候选集 C $\Rightarrow$ 筛选 $\Rightarrow$ 频繁项集 L₂

项集	support
Z, K	80%
Z, O	60%
K, M	60%
K, O	60%
K, Y	60%

cut { ① 项集
② support 计算

项集	s
Z, K, O	60%

{K, Z, M, O, Y
K, Z, O, Y
K, Z, M
K, M, Y
K, Z, O

原理?


② FP-growth 算法

"frequent-pattern growth"

项集 支持度 链接

null {}

FP 树




② FP-growth 算法

"frequent-pattern growth"

原理?

项集 支持度 排序

K	100%
Z	80%
M	60%
O	60%
Y	60%



项 条件模式基 条件FP树 与Apriori算法结果对比

Y	$\langle K, Z, M, O:1 \rangle, \langle K, Z, O:1 \rangle, \langle K, M:1 \rangle$	$\langle K:3 \rangle$	$\langle K, Y:3 \rangle$
O	$\langle K, Z, M:1 \rangle, \langle K, Z, O:2 \rangle$	$\langle K:3, Z:3 \rangle$	$\langle K, O:3 \rangle, \langle O, Z:3 \rangle, \langle K, Z, O:3 \rangle$
M	$\langle K, Z:2 \rangle, \langle K:1 \rangle$	$\langle K:3 \rangle$	$\langle K, M:3 \rangle$
Z	$\langle K:4 \rangle$	$\langle K:4 \rangle$	$\langle K, Z:4 \rangle$

Apriori 算法易于理解, 但需要多次扫描数据集, 效率较低

FP-growth 算法只需扫描2次数据集, 效率较高, 但内存开销较大

由题可知数据集包含频繁项集 $X = \{K, Z, O\}$ 均为60%

有 $\{K, Z\} \Rightarrow O$, $[S = 60\%, conf = \frac{S(K, Z, O)}{S(K, Z)} = \frac{0.6}{0.8} = 75\%]$

$\{K, O\} \Rightarrow Z$, $[S = 60\%, conf = \frac{0.6}{0.6} = 100\%]$

0 $\langle k, z, M:1 \rangle \langle k, z, 0:2 \rangle \langle k, z, 3 \rangle$ $\langle k, 0:3 \rangle \langle 0, z:3 \rangle$
 $\langle k, z, 0:3 \rangle$

M $\langle k, z:2 \rangle \langle k:1 \rangle \langle k:3 \rangle \langle k, M:3 \rangle$

z $\langle k:4 \rangle \langle k:4 \rangle \langle k, z:4 \rangle$

Apriori 算法易于理解，但需要多次扫描数据集，效率较低

FP-growth 算法只需扫描 2 次数据集，效率较高，但内存开销较大

(2) 由题设数据集包含频繁项集 $X = \{k, z, 0\}$

条件既充分

充分条件

有 $\{k, z\} \Rightarrow 0$, $[S = 60\%, \text{conf} = \frac{S(k, z, 0)}{S(k, z)} = \frac{0.6}{0.8} = 75\%]$

$\{k, 0\} \Rightarrow z$ $[S = 60\%, \text{conf} = \frac{0.6}{0.6} = 100\%]$

$\{0, z\} \Rightarrow k$ $[S = 60\%, \text{conf} = \frac{0.6}{0.6} = 100\%]$

$k \Rightarrow \{z, 0\}$ $[S = 60\%, \text{conf} = \frac{0.6}{1} = 60\%]$

$z \Rightarrow \{k, 0\}$ $[S = 60\%, \text{conf} = \frac{0.6}{0.8} = 75\%]$

$0 \Rightarrow \{k, z\}$ $[S = 60\%, \text{conf} = \frac{0.6}{0.6} = 100\%]$

$\therefore \min\text{-conf} = 80\%$

条件既充分

充分条件

强关联规则:

$\{k, 0\} \Rightarrow z$

$\{0, z\} \Rightarrow k$

$0 \Rightarrow \{k, z\}$