

《计算机网络应用综合实践》选题登记表

模块六：大数据/云计算/开源分布式服务器集群系统的部署及应用（共计 17 个候选题目）

（一）基于Hadoop平台的HDFS分布式文件服务器集群系统及其应用（2）：

| 序 | 题目                                 | 任务具体要求                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               | 难度   | 人数 | 学 号 | 姓 名 |
|---|------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于Hadoop安装配置HDFS分布式文件系统集群（伪分布式模式）  | <p>建议Hadoop课题采用的服务器集群共五个虚拟机，cMaster为主节点，cProxy为主节点代理，cSlave1和cSlave2为2个Slave节点，以及客户端iClient节点。注意iClient并不属于集群，用户须确保上述集群中所有系统和iClient都可以连网。建议Hadoop版本采用2.0以上版本，各节点OS系统采用CentOS-6.4 版或更新版，JDK采用jdk-7u45-linux-x64.rpm 版或更新版，部署测试代码的执行在iClient节点上。Hadoop包含HDFS和Yarn两大基础服务，其中HDFS主服务称为namenode进程，应当运行在cMaster机上，HDFS从服务运行datanode进程，正常应部署在Slave机器上，并且每个slave运行一个datanode。</p> <p>本模块下Hadoop平台上的各个选题的安装部署一般流程为：</p> <p>1、准备软硬件虚拟机环境</p> <p>2、下载组件的rpm文件或源码压缩包</p> <p>3、将rpm文件复制到各节点OS，或按需将解压且配置好的组件发送到需要部署的机器OS</p> <p>4、新建本地用户、相应存储目录等，并赋予合适权限，然后启动相应服务</p> <p>5、若需通过Web界面管理某组件，配置部署相应的Web管理工具。</p> <p>本课题要求实现HDFS集群系统伪分布式模式的部署，以及相关各节点上如iClient上的配置、测试过程。文件服务测试可利用Xshell 及 Xftp 进行。</p> | 9-10 | 1  |     |     |
| 2 | 基于Hadoop安装配置HDFS分布式文件系统集群（完全分布式模式） | <p>建议Hadoop课题采用的服务器集群共五个虚拟机，cMaster为主节点，cProxy为主节点代理，cSlave1和cSlave2为2个Slave节点，以及客户端iClient节点。注意iClient并不属于集群，用户须确保上述集群中所有系统和iClient都可以连网。建议Hadoop版本采用2.0以上版本，各节点OS系统采用CentOS-6.4 版或更新版，JDK采用jdk-7u45-linux-x64.rpm 版或更新版，部署测试代码的执行在iClient节点上。Hadoop包含HDFS和Yarn两大基础服务，其中HDFS主服务称为namenode进程，应当运行在cMaster机上，HDFS从服务运行datanode进程，正常应部署在Slave机器上，并且每个slave运行一个datanode。</p> <p>本模块下Hadoop平台上的各个选题的安装部署一般流程为：</p> <p>1、准备软硬件虚拟机环境</p> <p>2、下载组件的rpm文件或源码压缩包</p> <p>3、将rpm文件复制到各节点OS，或按需将解压且配置好的组件发送到需要部署的机器OS</p> <p>4、新建本地用户、相应存储目录等，并赋予合适权限，然后启动相应服务</p> <p>5、若需通过Web界面管理某组件，配置部署相应的Web管理工具。</p> <p>本课题要求实现HDFS集群系统完全分布式模式的部署，及相关各节点上如iClient上的配置、测试过程。文件服务测试可利用Xshell 及 Xftp 进行。</p> | 9-10 | 1  |     |     |

（二）基于Hadoop平台的MapReduce分布式离线计算服务器集群及其应用（1）：

| 序 | 题目                                  | 任务具体要求                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      | 难度   | 人数 | 学 号 | 姓 名 |
|---|-------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于Hadoop平台配置实现MapReduce分布式离线计算服务器集群 | <p>注：Hadoop MapReduce是一个使用简便的软件框架，是Google云计算模型MapReduce的Java开源实现，基于它写出来的应用程序能够运行在由上千万台普通机器注册的大型集群系统中，并以一种可靠地、容错的方式并行处理上T级别的数据集。MapReduce基本思想是：将计算过程分为两个阶段：Map和Reduce。一个MapReduce作业通常会把输入的数据集合切分为若干独立的数据块，由Map任务并行的方式处理数据。该框架会对Map的输出先进行排序，然后把结果输出作为Reduce任务的输入，对Map的结果进行汇总，通常结果的输入和输出都会存储在文件系统中。与传统的分布式程序设计相比，MapReduce封装了并行处理、容错处理、本地化计算、负载均衡等细节，还提供了一个简单而强大的接口。MapReduce把对数据集的大规模操作，分发给一个主节点管理下的各分节点共同完成，通过这种方式实现任务的可靠执行与容错机制。</p> <p>建议Hadoop课题采用的服务器集群共五个虚拟机，cMaster为主节点，cProxy为主节点代理，cSlave1和cSlave2为2个Slave节点，以及客户端iClient节点。注意iClient并不属于集群，用户须确保上述集群中所有系统和iClient都可以连网。建议Hadoop版本采用2.0以上版本，各节点OS系统采用CentOS-6.4 版或更新版，JDK采用jdk-7u45-linux-x64.rpm 版或更新版，部署测试代码的执行在iClient节点上。</p> <p>本模块下Hadoop平台上的各个选题的安装部署一般流程为：</p> <p>1、准备软硬件虚拟机环境</p> <p>2、下载组件的rpm文件或源码压缩包</p> <p>3、将rpm文件复制到各节点OS，或按需将解压且配置好的组件发送到需要部署的机器OS</p> <p>4、新建本地用户、相应存储目录等，并赋予合适权限，然后启动相应服务</p> <p>5、若需通过Web界面管理某组件，配置部署相应的Web管理工具。</p> <p>本课题要求利用MapReduce实现的分布式数据处理集群系统完成字符串文本按首字母排序的任务（字典序），应实现的配置测试主要包括如下：</p> <p>步骤1：对原始的数据进行分割（Split），得到N个不同的数据分块。</p> <p>步骤2：对每一个数据分块都启动一个Map进行处理。例如采用桶排序的方法，将每个Map中按照首字母将字符串分配到26个不同的桶中。</p> | 9-10 | 1  |     |     |

|  |  |                                                                           |  |  |  |  |
|--|--|---------------------------------------------------------------------------|--|--|--|--|
|  |  | 对于Map之后得到的中间结果，启动26个Reduce。<br>步骤3：按照首字母将Map中不同桶中的字符串集合放置到相应的Reduce中进行处理。 |  |  |  |  |
|--|--|---------------------------------------------------------------------------|--|--|--|--|

（三）基于开源Spark项目的分布式计算及数据挖掘系统及其应用（2）：

| 序 | 题目                          | 任务具体要求                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      | 难度   | 人数 | 学 号 | 姓 名 |
|---|-----------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于开源 Spark Mlib 的分布式计算系统实践  | 注： MLLIB是Spark的机器学习库。它提供了利用Spark构建大规模和易用性的机器学习平台，其五大特性为：1-ML算法（包含机器学习分类算法、聚类算法、属性降维算法、协同过滤算法等）；2-特征化（特征抽取、特征转换、特征选择、特征降维）；3-管道Pipeline（将数据处理或特征工程的流程按照管道的方式去串联）；4-持久化Persistence（保存模型，保存管道。所谓保存模型即将已经训练好的模型保存在本地或hdfs中，在本地或hdfs中加载已经训练好的模型后可直接做预测分析）；5-工具（包括线性代数、统计学、数据处理科学）。本课题要求的各组件版本不低于：JDK v1.8.0 + Spark v2.3.2 + Hadoop v2.7 + Scala v2.11.8。部署方案请参考文章： <a href="https://blog.csdn.net/xxubing123/article/details/86516631">https://blog.csdn.net/xxubing123/article/details/86516631</a><br>本课题要求下载Spark、hadoop on windows或Hadoop、JDK、IntelliJ IDEA、scala、IntelliJ-scala plug等组件，然后完成JAVA环境配置、Hadoop环境配置、Spark环境配置、Scala环境配置、IDE配置等，然后在IDE中创建新项目（选择Project SDK）、安装scala插件后重启IntelliJ、添加spark library、创建一个Sparkdemo的object、ctrl+shift+F10运行之。要求在你的项目中部署实施某种机器学习ML算法。 | 9-10 | 1  |     |     |
| 2 | 基于开源 Spark SQL 的分布式数据挖掘系统实践 | 注：Spark SQL是Spark套件中的一个模块，它将数据的计算任务通过SQL的形式转换成了RDD的计算，类似于Hive通过SQL的形式将数据的计算任务转换成了MapReduce。本课题要求的各组件版本不低于：JDK v1.8.0 + Spark v2.3.2 + Hadoop v2.7 + Scala v2.11.8 + Hive v3.1.3（这里主要是使用Hive 来维护 Spark SQL表和分布式存储中文件的关系）+ MySQL v5.6。请注意Spark SQL官方提供的二进制下载版本缺少对Hive的支持，需要自己下载源码并加入Hive依赖，然后生成安装包。部署方案请参考文章： <a href="https://www.modb.pro/db/405627">https://www.modb.pro/db/405627</a> 和 <a href="https://www.modb.pro/db/411987">https://www.modb.pro/db/411987</a> 。本课题要求在你的项目中部署实施TPC-H（商业智能计算测试，是国际交易处理效能委员会(TPC,Transaction Processing Performance Council) 组织制定的用来模拟决策支持类应用的一个测试方案）。                                                                                                                                                                                 | 9-10 | 1  |     |     |

（四）基于Hadoop的Sqoop分布式结构化数据库服务器及其应用（1）：

| 序 | 题目                             | 任务具体要求                                                                                                                                                                                                                                                                                                                                                                                                                      | 难度   | 人数 | 学 号 | 姓 名 |
|---|--------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于Hadoop的Sqoop分布式结构化数据库服务器群集系统 | 注：Apache的Hadoop大家族中的Sqoop是其分布式结构化数据库数据与半结构化数据之间的迁移转换工具组件，可将一个关系型数据库（MySQL 、Oracle 、Postgres等）中的数据导入Hadoop的HDFS中，也可以将HDFS的数据导入关系型数据库中。本课题要求部署实现将MySQL数据导入HDFS、将HDFS数据导入MySQL、将MySQL数据导入Hive、将Hive数据导入MySQL、将MySQL数据导入OSS、将OSS数据导入MySQL、以及通过SQL 命令语句书写导入条件的配置、测试验证的全过程。具体过程请参考文章： <a href="https://www.alibabacloud.com/help/zh/e-mapreduce/latest/sqoop">https://www.alibabacloud.com/help/zh/e-mapreduce/latest/sqoop</a> 。 | 9-10 | 1  |     |     |

（五）基于Hadoop平台的分布式非关系型数据服务器集群及应用（2）：

| 序 | 题目                               | 任务具体要求                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               | 难度   | 人数 | 学 号 | 姓 名 |
|---|----------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于Hadoop的HBase分布式非关系型数据服务器集群     | 注： Apache的Hadoop大家族中的Hbase是其分布式的非关系型数据存储服务组件，可实现高可靠性、高性能、面向列、可伸缩的分布式数据存取服务。可用它在廉价PC Server上搭建大规模结构化存储集群。HBase是一个可以进行随机访问的存储和检索数据的平台，用于存储结构化和半结构化的数据，如果数据量不是非常庞大的情况下，Hbase甚至可以存储非结构化的数据。Hbase作为Apache基金会Hadoop项目的一部分，使用Java语言实现，将HDFS作为底层文件存储系统，在此基础上运行MapReduce分布式批量处理数据，为Hadoop提供海量的数据管理服务。Hbase是典型的NoSQL数据库，通常被描述为稀疏的、分布式的、持久化的，由行键、列键和时间戳进行索引的多维有序映射数据库，主要用来储存结构化和半结构化的数据。Hbase是Google的Bigtable的开源实现。具体部署过程请参考文章： <a href="https://zhuanlan.zhihu.com/p/389673280">https://zhuanlan.zhihu.com/p/389673280</a> 。本课题要求基于zookeeper部署实现HBase的完全分布式环境。 | 9-10 | 1  |     |     |
| 2 | 基于Hadoop的Cassandra分布式非关系型数据服务器集群 | 注： Apache的Hadoop大家族中的Cassandra是一套开源分布式NoSQL数据库系统。它最初由Facebook开发，用于储存收件箱等简单格式数据，集GoogleBigTable的数据模型与Amazon Dynamo的完全分布式的架构于一身。Cassandra是一个混合型的非关系的数据库，类似于Google的BigTable。Cassandra的主要特点就是它不是一个数据库，而是由一堆数据库节点共同构成的一个分布式网络服务，对Cassandra的一个写操作，会被复制到其他节点上去，对Cassandra的读操作，也会被路由到某个节点上面去读取。对于一个Cassandra群集来说，扩展性能是比较简单的事情，只管在群集里面添加节点就可以了。具体部署过程请参考文章： <a href="https://www.likecs.com/show-204055553.html">https://www.likecs.com/show-204055553.html</a> 。本课题要求部署实现用cqlsh编写各种sql数据定义和查询操作语句。                                                           | 9-10 | 1  |     |     |

（六）基于Hadoop平台的Hive/Hive2数据仓库系统及其应用（2）：

| 序 | 题目                           | 任务具体要求                                                                                                                                                                                                                          | 难度   | 人数 | 学 号 | 姓 名 |
|---|------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于Hadoop的Hive2现对数据仓库系统的分析与管理 | 注：Apache的Hadoop大家族中的Hive/Hive2/Hive3是其数据仓库管理组件，它将结构化的数据文件映射为一张数据库表，通过类SQL语句对数据文件进行读写以及管理，可快速实现简单的MR统计，适合数据仓库的统计分析。这套Hive SQL简称HQL。Hive的执行引擎可以是MR、Spark、Tez。本课题要求在HDFS+YARN环境（完全分布式5节点集群）的基础上，将元数据部署在MySQL服务器上，并在2个Hive服务器上创建其数据 | 9-10 | 1  |     |     |

|   |                               |                                                                                                                                                                                                                                             |      |   |  |  |
|---|-------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|---|--|--|
|   |                               | 仓库，然后分别通过多个Hive客户端实现对数据仓库的各种SQL操作。并在上述环境中实践演示Hive2相较于Hive的那些新增功能和特性。                                                                                                                                                                        |      |   |  |  |
| 2 | 基于Hadoop的Hive3实现对数据仓库系统的分析与管理 | 注：Apache的Hadoop大家族中的Hive/Hive2是其数据仓库管理组件，它将结构化的数据文件映射为一张数据库表，并提供SQL查询功能，能将SQL语句转变成MapReduce任务来执行。本课题要求在HDFS+YARN环境（完全分布式5节点集群）的基础上，将元数据部署在MySQL服务器上，并在2个Hive2服务器上创建其数据仓库，然后分别通过多个Hive客户端实现对数据仓库的各种SQL操作。并在上述环境中实践演示Hive3相较于Hive2的那些新增功能和特性。 | 9-10 | 1 |  |  |

（七）基于Hadoop平台的Pig/Pig2大规模数据分析系统及其应用（1）：

| 序 | 题目                      | 任务具体要求                                                                                                                                                                                                                                                                                 | 难度   | 人数 | 学 号 | 姓 名 |
|---|-------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于Hadoop的Pig实现大规模数据分析系统 | 注：Apache的Hadoop大家族中的Pig/Pig2是其分布式的大规模数据分析组件，由yahoo公司开源，提供类SQL类型语言（一种操作大规模数据集的脚本语言），该语言的编译器会把用户写好的Pig型类SQL脚本语言（Pig Latin）转换为一系列经过优化的MR操作并负责向集群提交任务。本课题要求在HDFS+YARN环境（完全分布式5节点集群，也称为Pig的MapReduce运行模式）的基础上，安装部署Pig组件，并实践分别使用Apache Pig的命令行编辑工具Pig grunt shell、Pig Latin脚本等方式进行数据分析操作的过程。 | 9-10 | 1  |     |     |

（八）基于开源Impala项目的新型分布式数据查询系统及其应用（1）：

| 序 | 题目                       | 任务具体要求                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 | 难度   | 人数 | 学 号 | 姓 名 |
|---|--------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于开源 Impala 的新型分布式数据查询系统 | 注：Impala是Cloudera公司主导开发的新型查询系统，它提供SQL语义，能查询存储在Hadoop的HDFS和HBase中的PB级大数据。Impala就是用于处理存储在Hadoop集群中的大量数据的MPP（大规模并行处理）SQL查询引擎。 它是一个用C++和Java编写的开源软件。与其他Hadoop的SQL引擎相比，它提供了高性能和低延迟。已有的Hive系统虽然也提供了SQL语义，但由于Hive底层执行使用的是MapReduce引擎，仍然是一个批处理过程，难以满足查询的交互性。相比之下，Impala的最大特点也是最大卖点就是它的快速。换句话说，Impala是性能最高的SQL引擎（提供类似RDBMS的体验），它提供了访问存储在Hadoop分布式文件系统的数据的最快方法。具体的部署方案可参照文档： <a href="https://blog.51cto.com/u_15105906/2864366">https://blog.51cto.com/u_15105906/2864366</a> 。本课题要求至少在分布式3节点集群的基础上（hadoop、hive正常服务并且配置好），安装部署Impala，并实践其DDL数据定义语言/DML数据操作语言、内部SHELL命令等查询操作的过程。 | 9-10 | 1  |     |     |

（九）基于Hadoop平台的YARN集群资源管理服务器系统及其应用（1）：

| 序 | 题目                      | 任务具体要求                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | 难度   | 人数 | 学 号 | 姓 名 |
|---|-------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于Hadoop的YARN实现集群资源管理系统 | 注： YARN是Hadoop中的资源管理系统，可将其看做是一个分布式云操作系统，它负责应用程序启动ApplicationMaster（相当于主进程），然后由ApplicationMaster进行数据切分、任务分配、启动和监控等工作，而由ApplicationMaster启动的各个Task(相当于子线程)仅仅负责自己的计算任务。资源管理系统地主要功能是对集群中各类资源进行抽象，并根据各种应用程序或者服务的要求，按照一定的调度策略，将资源分配给它们使用，同时采用一定的资源隔离机制防止应用程序或者服务之间因资源抢夺而相互干扰。YARN总体上仍然是Master/Slave结构，在整个资源管理框架中，ResourceManager为Master，NodeManager为Slave，ResourceManager负责对各个NodeManager上的资源进行统一管理和调度。本课题要求部署实现YARN服务器群集系统的资源调度和任务分配管理。其中YARN的作业调度器有三种：FIFO、容量（Capacity Scheduler）和公平（Fair Scheduler），在配置文件yarn-site.xml中可以对调度器类型进行设置，Apache Hadoop 3.1.3默认的资源调度器是Capacity Scheduler。本课题要求分别实现：通过yarn命令来对集群或任务运行情况进行查看；通过Web界面对Hadoop信息进行查看（9870端口）；通过配置好的历史服务器查看作业运行情况（19888/jobhistory）。特别提示：本课题难度很高。 | 9-10 | 1  |     |     |

（十）基于Hadoop的ZooKeeper分布式协作服务器系统及其应用（1）：

| 序 | 题目                             | 任务具体要求                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | 难度   | 人数 | 学 号 | 姓 名 |
|---|--------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|----|-----|-----|
| 1 | 基于Hadoop的ZooKeeper分布式协作服务器集群系统 | 注：Apache的Hadoop大家族中的Zookeeper是其分布式、开源的协调服务组件，主要是用来解决多个分布式应用遇到的互斥协作与通信问题，能大大简化分布式应用协调及其管理的难度。ZooKeeper是Apache的一个顶级项目，为分布式应用提供高效、高可用的分布式协调服务，提供了诸如数据发布/订阅、负载均衡、命名服务、分布式协调/通知和分布式锁等分布式基础服务。由于ZooKeeper便捷的使用方式、卓越的性能和良好的稳定性，被广泛地应用于诸如 Hadoop、HBase、Kafka 和 Dubbo 等大型分布式系统中。Zookeeper有三种运行模式：单机模式、伪集群模式和集群模式。zookeeper集群模式通常是用来对用户的分布式应用程序提供协调服务的，为了保证数据的一致性，对zookeeper集群进行了三种角色划分：leader、follower、observer分别对应着总统、议员和观察者。本课题要求至少在分布式3节点集群模式的基础上，部署实现zookeeper集群。特别提示：本课题难度很高。 | 9-10 | 1  |     |     |

（十一）基于Hadoop的Cloudera Hue实现对服务器群集系统的Web化管理操作（3）：

| 序 | 题目 | 任务具体要求 | 难度 | 人数 | 学 号 | 姓 名 |
|---|----|--------|----|----|-----|-----|
|---|----|--------|----|----|-----|-----|

|   |                                            |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |      |   |  |  |
|---|--------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|---|--|--|
| 1 | 基于Hadoop的Cloudera Hue实现对HDFS群集系统的Web化管理操作  | 注：Apache的Hadoop大家族中的Cloudera Hue是Hadoop及其生态圈组件的Web编辑工具，可实现对HDFS、Yarn、MapReduce、Hbase、Hive、Pig等的Web化操作。Hue是Cloudera开源的一个Hadoop UI，由Cloudera Desktop演化而来。面向用户提供方便的UI用于平时的Hadoop操作中。Hue由Cloudera贡献给开源社区，它是基于Python Web框架Django实现的。通过使用Hue我们可以在浏览器端的Web控制台上与Hadoop集群进行交互以便分析处理数据，例如操作HDFS上的数据，运行MapReduce Job等。请首先下载部署CDH版本（ <a href="https://link.zhihu.com/?target=http%3A//archive-primary.cloudera.com/cdh5/cdh/5/">https://link.zhihu.com/?target=http%3A//archive-primary.cloudera.com/cdh5/cdh/5/</a> ），本课题要求部署实现Cloudera Hue（推荐使用其稳定版本:hue-3.7.0-cdh5.3.6）与HDFS群集系统的集成。具体部署过程可参考文章： <a href="https://zhuanlan.zhihu.com/p/143555502">https://zhuanlan.zhihu.com/p/143555502</a> 。                                                                                                                                                                             | 9-10 | 1 |  |  |
| 2 | 基于Hadoop的Cloudera Hue实现对HIVE群集系统的Web化管理操作  | 注：Apache的Hadoop大家族中的Cloudera Hue是Hadoop及其生态圈组件的Web编辑工具，可实现对HDFS、Yarn、MapReduce、Hbase、Hive、Pig等的Web化操作。Hue是Cloudera开源的一个Hadoop UI，由Cloudera Desktop演化而来。面向用户提供方便的UI用于平时的Hadoop操作中。Hue由Cloudera贡献给开源社区，它是基于Python Web框架Django实现的。通过使用Hue我们可以在浏览器端的Web控制台上与Hadoop集群进行交互以便分析处理数据，例如操作HDFS上的数据，运行MapReduce Job等。请首先下载部署CDH版本（ <a href="https://link.zhihu.com/?target=http%3A//archive-primary.cloudera.com/cdh5/cdh/5/">https://link.zhihu.com/?target=http%3A//archive-primary.cloudera.com/cdh5/cdh/5/</a> ）和The open source SQL Assistant for Data Warehouses（ <a href="https://link.zhihu.com/?target=http%3A//gethue.com/">https://link.zhihu.com/?target=http%3A//gethue.com/</a> ）。本课题要求部署实现Cloudera Hue（推荐使用其稳定版本:hue-3.7.0-cdh5.3.6）与HIVE群集系统的集成。具体部署过程可参考文章： <a href="https://zhuanlan.zhihu.com/p/143555502">https://zhuanlan.zhihu.com/p/143555502</a> 。  | 9-10 | 1 |  |  |
| 3 | 基于Hadoop的Cloudera Hue实现对HBASE群集系统的Web化管理操作 | 注：Apache的Hadoop大家族中的Cloudera Hue是Hadoop及其生态圈组件的Web编辑工具，可实现对HDFS、Yarn、MapReduce、Hbase、Hive、Pig等的Web化操作。Hue是Cloudera开源的一个Hadoop UI，由Cloudera Desktop演化而来。面向用户提供方便的UI用于平时的Hadoop操作中。Hue由Cloudera贡献给开源社区，它是基于Python Web框架Django实现的。通过使用Hue我们可以在浏览器端的Web控制台上与Hadoop集群进行交互以便分析处理数据，例如操作HDFS上的数据，运行MapReduce Job等。请首先下载部署CDH版本（ <a href="https://link.zhihu.com/?target=http%3A//archive-primary.cloudera.com/cdh5/cdh/5/">https://link.zhihu.com/?target=http%3A//archive-primary.cloudera.com/cdh5/cdh/5/</a> ）和The open source SQL Assistant for Data Warehouses（ <a href="https://link.zhihu.com/?target=http%3A//gethue.com/">https://link.zhihu.com/?target=http%3A//gethue.com/</a> ）。本课题要求部署实现Cloudera Hue（推荐使用其稳定版本:hue-3.7.0-cdh5.3.6）与HBASE群集系统的集成。具体部署过程可参考文章： <a href="https://zhuanlan.zhihu.com/p/143555502">https://zhuanlan.zhihu.com/p/143555502</a> 。 | 9-10 | 1 |  |  |