

第 1 章练习题

- 1.1 什么是数据挖掘？（可以看一下课后 1.1 题）
- 1.2 当数据挖掘被看作知识发现时，包括几个步骤？
- 1.3 数据挖掘的功能是什么？
- 1.4 数据挖掘可以挖掘哪些数据？
- 1.5 列举 5 个数据挖掘的应用领域。

第 2 章练习题

- 2.2 假设所分析的数据包括属性 **age**，它在数据元组中的值（以递增序）为 13,15,16,16,19,20,21,22,22,25,25,25,25,30,33,33,35,35,35,35,36,40,45,46,52,70。
 - a) 该数的均值是多少？中位数是什么？
 - b) 该数据的众数是什么？讨论数据的模态（即二模、三模等）。
 - c) 数据的中列数是多少？
 - d) 你能粗略的找出该数据的第一个四分位数(Q1)，第三个四分位数(Q3)吗？
 - e) 给出该数据的五数概括。
 - f) 分位数-分位数图与分位数图有什么区别？

练习：已知奇数序列 93，81，76，87，66，79，83，求以上 a)-f)怎么求？

注意：做此类题先排序，计算分位数时，可以按照下面方法，如选择第一种：


2、度量数据散布：极差、四分位数、方差、标准差和四分位数极差

• 例子：

age
23
23
27
27
39
41
47
49
50
52
54
54
56
57
58
58
60
61

n=18

分位数位置 确定方法	四分之一分 位数位置	四分之三分 位数位置
第一种	$\frac{n+1}{4}$	$\frac{3(n+1)}{4}$
第二种	$\frac{n-1}{4}$	$\frac{3(n-1)}{4}$
第三种	$1 + \frac{n-1}{4}$	$1 + \frac{3(n-1)}{4}$



假设： X_i 的整数部分表示为 $[X_i]$ ，小数部分表示为 $\{X_i\}$ ，四分位数的值为 Y ，对原始数列进行升序排序后，第 j 位的数表示为 D_j

那么：第 i 个四分位数的值 Y_i 可以表示为如下公式：

$$Y_i = D_{[X_i]} + \{X_i\}(D_{[X_i]+1} - D_{[X_i]})$$


2、度量数据散布：极差、四分位数、方差、标准差和四分位数极差

• 五数概括、盒图与离群点

➤ 离群点

□ 识别规则——挑选落在第3个四分位数之上或第1个四分位数之下 $1.5 \times \text{IQR}$ 处的值。

盒图上界	$Q3 + 1.5 \times \text{IQR} > \max$	max
	$Q3 + 1.5 \times \text{IQR} < \max$	$Q3 + 1.5 \times \text{IQR}$
盒图下界	$Q1 - 1.5 \times \text{IQR} > \min$	$Q1 - 1.5 \times \text{IQR}$
	$Q1 - 1.5 \times \text{IQR} < \min$	min



2.6 给定两个被元组(22,1,42,10)和(20,0,36,8)表示的对象。

- 计算这两个对象之间的欧几里得距离。
- 计算这两个对象之间的曼哈顿距离。
- 使用 $q=3$ ，计算这两个对象之间的闵可夫斯基距离。
- 计算这两个对象之间的上确界距离。
- 计算两个对象的余弦相似度。

第 3 章练习题

3.3 在习题 2.2 中，属性 **age** 包括如下值（以递增序）：13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33, 35, 35, 35, 35, 36, 40, 45, 46, 52, 70.

(a) 使用深度为 3 的箱，用箱均值光滑以上的数据。说明你的步骤，讨论这种技术对给定数据的效果。

(b) 如何确定该数据中的离群点？

(c) 还有什么其他方法来光滑数据，用这些方法对(a)中各箱数据进行光滑。

3.6 使用如下方法规范化如下数据组：200, 300, 400, 600, 1000

(a) 另 $\min=0$, $\max=1$, 最小-最大规范化

(b) 小数定标规范化

3.7 使用习题 3.3 中给出的 age 数据，回答以下问题：

(a)使用最小-最大规范化将 age 值 35 变换到[0.0, 1.0]区间

(b)使用 z 分数规范化变换 age 值 35，其中 age 的标准差为 12.94 岁

(c)使用小数定标规范化变换 age 值 35

(d)指出对于给定的数据，你愿意使用哪种方法。陈述你的理由。

卡方检验：

2、冗余和相关分析

1) 标称数据的 χ^2 相关检验

例子：性别与阅读偏好相关吗？

$$\chi^2 = \sum_{i=1}^c \sum_{j=1}^r \frac{(o_{ij} - e_{ij})^2}{e_{ij}}$$

$$e_{11} = \frac{\text{count}(\text{男}) \times \text{count}(\text{小说})}{n} = \frac{300 \times 450}{1500} = 90$$

	男	女	合计
小说	250	200	450
非小说	50	1000	1050
合计	300	1200	1500

计算期望频度 e_{ij}

$$e_{ij} = \frac{\text{count}(A = a_i) \times \text{count}(B = b_j)}{n}$$

	男	女
小说	90	360
非小说	210	840

计算性别与阅读偏好的 χ^2 ：

$$\chi^2 = \sum_{i=1}^c \sum_{j=1}^r \frac{(o_{ij} - e_{ij})^2}{e_{ij}}$$

$$= \frac{(250 - 90)^2}{90} + \frac{(50 - 210)^2}{210} + \frac{(200 - 360)^2}{360} + \frac{(1000 - 840)^2}{840}$$

$$= 284.44 + 121.90 + 71.11 + 30.48 = 507.93 > 10.828, \text{说明性别与阅读偏好强相关。}$$

自由度：

$$k = (C-1)(R-1) = (2-1)(2-1) = 1$$

置信水平：0.001

第 4 章练习题

4.1 什么是数据仓库？

4.2 数据仓库的三层体系结构是什么？

4.3 多维数据模型的模式有哪些？

4.4 典型的 OLAP 操作有哪些？

4.5 列举 OLTP 与 OLAP 在五个方面的不同。

第 6 章作业

6.6 数据库有 5 个事物。设 min_sup=60%，min_conf=80%。

TID

购买的商品

T100	{M, O, N, K, E, Y}
T200	{D, O, N, K, E, Y}
T300	{M, A, K, E}
T400	{M, U, C, K, Y}
T500	{C, O, O, K, I, E}

(a) 分别使用Apriori 和FP-growth算法找出频繁项集。比较两种挖掘过程的有效性。

(b) 列举所有与下面的元规则匹配的强关联规则（给出支持度s和置信度c），其中，X 是代表顾客的变量，item_i 是表示项的变量（如“A”、“B”等）：

$$\forall x \in \text{transaction}, \text{buys}(X, \text{item}_1) \wedge \text{buys}(X, \text{item}_2) \Rightarrow \text{buys}(X, \text{item}_3) [s, c]$$


可以练习课件中的题，包括 Apriori 算法和 FP-growth 算法：

1、Apriori算法：通过限制候选产生发现频繁项集

例1: $\min_sup=2$

TID	商品ID的列表
T100	I1, I2, I5
T200	I2, I4
T300	I2, I3
T400	I1, I2, I4
T500	I1, I3
T600	I2, I3
T700	I1, I3
T800	I1, I2, I3, I5
T900	I1, I2, I3

$C_3 = L_2 \times L_2$
 I1, I2, I3
 I1, I2, I5
 I1, I3, I5
 I2, I3, I4
 I2, I3, I5
 I2, I4, I5




1、Apriori算法：通过限制候选产生发现频繁项集

例2: $\min_sup=2$

Database TDB

Tid	Items
10	A, C, D
20	B, C, E
30	A, B, C, E
40	B, E



6.14 下面的相依表汇总了超市的事务数据。其中，hot dogs 表示包含热狗的事务， $\overline{hot\ dogs}$ 表

示不包含热狗的事务，hamburgers 表示包含汉堡包的事务， $\overline{hamburgers}$ 表示不包含汉堡包的事务。

	hot dogs	$\overline{hot\ dogs}$	$\sum_{row}$
hamburgers	2000	500	2500
$\overline{hamburgers}$	1000	1500	2500
$\sum_{col}$	3000	2000	5000

- 假设挖掘出了关联规则“hot dogs=>hamburgers”。给定最小支持度阈值 25%，最小置信度阈值 50%，该关联规则是强规则吗？
- 根据给定的数据，买 hot dogs 独立买 hamburgers 吗？如果不是，两者之间存在何种相关联系？
- 在给定的数据上，将全置信度、最大置信度、Kulczynski 和余弦的使用与提升度和相关度进行比较。

各模式评估度量的计算：

3、模式评估度量比较

给定两个项集A和B，其他4种相关性度量：

- 4个度量仅受A、B和AUB的支持度的影响，或者说仅受条件概率 $P(A|B)$ 、 $P(B|A)$ 的影响，而不受事务总个数的影响。
- 取值都介于0~1之间，**值越大二者联系越紧密。**

(1) 全置信度

$$all_conf(A, B) = \frac{sup(AUB)}{\max\{sup(A), sup(B)\}} = \min\{P(A|B), P(B|A)\}$$

$all_conf(A, B)$ 又称两个与A和B相关的关联规则” $A \Rightarrow B$ ”和” $B \Rightarrow A$ ”的最小置信度。

(2) 最大置信度

$$max_conf(A, B) = \max\{P(A|B), P(B|A)\}$$

(3) Kulczynski (Kulc)度量

$$Kulc(A, B) = \frac{1}{2}(P(A|B) + P(B|A))$$

(4) 余弦度量

$$cosine(A, B) = \frac{P(A \cup B)}{\sqrt{P(A) \times P(B)}} = \frac{sup(AUB)}{\sqrt{sup(A) \times sup(B)}} = \sqrt{P(A|B) \times P(B|A)}$$

第 8 章练习题

8.1、决策树相关问题

- 决策树的属性度量包含哪几种，他们分别对应的算法是什么？


(2) 树剪枝包括哪几种，剪枝的目的是什么？

(3) 使用下表的数据作为训练数据集，利用基尼指数生成决策树。

ID	年龄	有工作	有自己的房子	信贷情况	类别
1	青年	否	否	一般	否
2	青年	否	否	好	否
3	青年	是	否	好	是
4	青年	是	是	一般	是
5	青年	否	否	一般	否
6	中年	否	否	一般	否
7	中年	否	否	好	否
8	中年	是	是	好	是
9	中年	否	是	非常好	是
10	中年	否	是	非常好	是
11	老年	否	是	非常好	是
12	老年	否	是	好	是
13	老年	是	否	好	是
14	老年	是	否	非常好	是
15	老年	否	否	一般	否

仿照 ppt 中计算的方式：

- 对于二元属性，结点被划分成两个部分，得到的Gini值越小，这种划分越可行。




	N ₁	N ₂
C0	4	2
C1	3	3
Gini	= 0.486	

$$\text{Gini}(N1) = 1 - (4/7)^2 - (3/7)^2 = 0.49$$

$$\text{Gini}(N2) = 1 - (2/5)^2 - (3/5)^2 = 0.48$$

$$\text{Gini}_{\text{split}} = 7/12 * 0.49 + 5/12 * 0.48 = 0.49$$



	N ₁	N ₂
C0	1	5
C1	4	2
Gini	= 0.371	

$$\text{Gini}(N1) = 1 - (1/5)^2 - (4/5)^2 = 0.32$$

$$\text{Gini}(N2) = 1 - (5/7)^2 - (2/7)^2 = 0.41$$

$$\text{Gini}_{\text{split}} = 5/12 * 0.32 + 7/12 * 0.41 = 0.37$$

B与A相比获得了更小的Gini值，它比A更可取。

8.2、分类器性能的度量

(1) 使用随机森林在某个数据集上进行分类获得的混淆矩阵如下，请计算相关的度量值。

混淆矩阵 1

		预测的类	
		yes	no
实际的类	yes	119	35
	no	32	116

	Yes			no		
准确率	精度	召回率	F1	精度	召回率	F1

混淆矩阵 2

		预测的类	
		yes	no
实际的类	yes	10	7
	no	2	151

	Yes			no		
准确率	精度	召回率	F1	精度	召回率	F1

(2) 根据混淆矩阵 1 和混淆矩阵 2 所获得度量比较，准确率是否均能反应分类器的性能，如果不能为什么，还有哪些更适合的分类器度量？针对类不均衡问题如何处理？

第 10 章练习题

10.2 假设数据挖掘的任务是将如下的 8 个点（用 (x,y) 代表位置）聚类为 3 个簇。

$A_1(2,10)$, $A_2(2,5)$, $A_3(8,4)$, $B_1(5,8)$, $B_2(7,5)$, $B_3(6,4)$, $C_1(1,2)$, $C_2(4,9)$

距离函数是欧氏距离。假设初始我们选择 A_1 , B_1 和 C_1 分别为每个簇的中心，用 k-均值算法给出：

- (a) 在第一轮执行后的 3 个簇中心点。
- (b) 最后的 3 个簇。

10.16 按如下标准对下列每种聚类方法进行描述：(1) 属于的聚类方法；(2) 可以确定的簇的形状；(3) 必须指定的输入参数。[\(可以看 PPT 的总结\)](#)

- (a) k-均值
- (b) k-中心点
- (c) BIRCH
- (d) CHAMELEON
- (e) DBSCAN
- (f) OPTICS
- (g) STING
- (h) CLIQUE