



石河子大学信息科学与技术学院

〈数据挖掘〉课程实验报告

实验名称:	实验 7 划分方法和层次方法聚类
学生姓名:	卢瑶
学 号:	20211018341
学 院:	信息科学与技术学院
专业年级:	计科 2021 级 5 班
指导教师:	刘雅辉
完成日期:	2024. 4. 24

实验 7 划分方法和层次方法聚类

一、实验目的

- 1、掌握 K-means、AgglomerativeClustering、BIRCH 的原理。
- 2、掌握 K-means、AgglomerativeClustering、BIRCH 算法的调参技巧和使用方法。

二、实验原理

K-means（K-均值）算法是无监督的聚类算法，其思想是：对于给定的样本集，按照样本之间的距离大小，将样本集划分为 K 个簇，使簇内的点尽量紧密的连在一起，而让簇间的距离尽量大。

AgglomerativeClustering 使用自下而上的方法执行层次聚类：每个观察都从其自己的聚类开始，并且聚类连续合并在一起。

BIRCH（Balanced Iterative Reducing and Clustering using Hierarchies, BIRCH），利用层次结构的平衡迭代规约和聚类，是为大量数值数据聚类设计的。BIRCH 使用聚类特征来概括一个簇，使用聚类特征树来表示聚类的层次结构。

三、实验环境

使用 scikit-learn 中的 K-means、BIRCH 算法

参考网址：K-means: <https://scikit-learn.org.cn/view/108.html#2.3.2.%20K-means>

AgglomerativeClustering: <https://scikit-learn.org.cn/view/371.html>

BIRCH: <https://scikit-learn.org.cn/view/108.html#2.3.9.%20Birch>

四、实验数据

linedata-cluster

moons-cluster

circle-cluster

五、实验要求：

本次实验，利用 K-means、AgglomerativeClustering、BIRCH 进行聚类，并比较他们的聚类效果。

六、实验步骤和结果

首先，我们构造实验所需代码，如下所示：

```
1. # 导入必要的库
2. from sklearn.cluster import KMeans, AgglomerativeClustering, Birch
3. from sklearn.datasets import make_blobs, make_moons, make_circles
4. import matplotlib.pyplot as plt
5. import numpy as np
6.
7. # 生成实验数据
8. np.random.seed(0)
```

```
9. n_samples = 1500
10.random_state = 170
11.X_linedata, y_linedata = make_blobs(n_samples=n_samples, random_state=random_state) #生成线型数据
12.X_moons, y_moons = make_moons(n_samples=n_samples, noise=0.05) #生成 月亮型数据
13.X_circle, y_circle = make_circles(n_samples=n_samples, factor=0.5, noise=0.05) #圆形数据
14.
15.# 定义K-means 聚类
16.kmeans = KMeans(n_clusters=3, random_state=random_state)
17.
18.# 定义层次聚类
19.agгло = AgglomerativeClustering(n_clusters=3)
20.
21.# 定义BIRCH 聚类
22.birch = Birch(n_clusters=3)
23.
24.# K-means 聚类
25.y_pred = kmeans.fit_predict(X_linedata)
26.plt.scatter(X_linedata[:, 0], X_linedata[:, 1], c=y_pred)
27.plt.title("KMeans on linedata")
28.plt.savefig('/Users/luyao/Desktop/课内/DM/EX/EX_7/KMeans on linedata.png')
29.plt.clf()
30.
31.y_pred = kmeans.fit_predict(X_moons)
32.plt.scatter(X_moons[:, 0], X_moons[:, 1], c=y_pred)
33.plt.title("KMeans on moons")
34.plt.savefig('/Users/luyao/Desktop/课内/DM/EX/EX_7/KMeans on moons.png')
35.plt.clf()
36.
37.y_pred = kmeans.fit_predict(X_circle)
38.plt.scatter(X_circle[:, 0], X_circle[:, 1], c=y_pred)
39.plt.title("KMeans on circle")
40.plt.savefig('/Users/luyao/Desktop/课内/DM/EX/EX_7/KMeans on circle.png')
41.plt.clf()
42.
43.# AgglomerativeClustering 聚类
44.y_pred = agгло.fit_predict(X_linedata)
45.plt.scatter(X_linedata[:, 0], X_linedata[:, 1], c=y_pred)
46.plt.title("AgglomerativeClustering on linedata")
47.plt.savefig('/Users/luyao/Desktop/课内/DM/EX/EX_7/AgglomerativeClustering on linedata.png')
48.plt.clf()
```

```

49.
50.y_pred = agгло.fit_predict(X_moons)
51.plt.scatter(X_moons[:, 0], X_moons[:, 1], c=y_pred)
52.plt.title("AgglomerativeClustering on moons")
53.plt.savefig('/Users/luyao/Desktop/课内
    /DM/EX/EX_7/AgglomerativeClustering on moons.png')
54.plt.clf()
55.
56.y_pred = agгло.fit_predict(X_circle)
57.plt.scatter(X_circle[:, 0], X_circle[:, 1], c=y_pred)
58.plt.title("AgglomerativeClustering on circle")
59.plt.savefig('/Users/luyao/Desktop/课内
    /DM/EX/EX_7/AgglomerativeClustering on circle.png')
60.plt.clf()
61.
62.# BIRCH 聚类
63.y_pred = birch.fit_predict(X_linedata)
64.plt.scatter(X_linedata[:, 0], X_linedata[:, 1], c=y_pred)
65.plt.title("BIRCH on linedata")
66.plt.savefig('/Users/luyao/Desktop/课内/DM/EX/EX_7/BIRCH on linedata.png')
67.plt.clf()
68.
69.y_pred = birch.fit_predict(X_moons)
70.plt.scatter(X_moons[:, 0], X_moons[:, 1], c=y_pred)
71.plt.title("BIRCH on moons")
72.plt.savefig('/Users/luyao/Desktop/课内/DM/EX/EX_7/BIRCH on moons.png')
73.plt.clf()
74.
75.y_pred = birch.fit_predict(X_circle)
76.plt.scatter(X_circle[:, 0], X_circle[:, 1], c=y_pred)
77.plt.title("BIRCH on circle")
78.plt.savefig('/Users/luyao/Desktop/课内/DM/EX/EX_7/BIRCH on circle.png')
79.plt.clf()

```

运行 python 代码，得到以下聚类结果：

(1) K-means 聚类结果:




图 1 K-means 聚类结果可视化

(2) 层次聚类结果




图 2 层次聚类结果可视化

(3) BIRCH 聚类结果




图 3 BIRCH 聚类结果可视化

七、实验结果分析

1. K-means 聚类结果分析:

- 在线型数据集上, K-means 应该能够准确地区分不同的簇, 因为这种数据分布适合其基于距离的聚类特性。
- 月亮型数据集可能会对 K-means 构成挑战, 因为 K-means 倾向于识别球形簇, 而月亮型的数据包含两个密集的非线性分布, 可能导致分类不准确。
- 圆形数据集同样也是 K-means 的挑战, 尤其是包含嵌套圆的情况, K-means 可能无法恰当地分离。

2. AgglomerativeClustering 层次聚类结果分析:

- 对于线型数据, 层次聚类方法可能会展现出与 K-means 类似的效果, 但这取决于所选用的距离度量和链接标准。
- 在月亮型数据集上, 层次聚类可能会有更好的表现, 因为它不依赖于球形簇的假设, 并且可以通过选择合适的链接策略来识别复杂的数据结构。
- 对于圆形数据集, 层次聚类同样可能表现出优于 K-means 的性能, 尤其是如果使用了适当的链接准则。

3. BIRCH 聚类结果分析:

- BIRCH 专为大规模数据集设计, 它使用了一种树结构来帮助识别簇, 这种结构可以处理噪声并识别不规则的簇形状。
- 在线型数据集上, BIRCH 应该表现良好, 可以准确地区分出簇。
- 对于月亮型和圆形数据集, BIRCH 可能会利用其树结构特性较好地识别出簇的形状。

八、本次实验的主要收获和体会, 使用 K-means、BIRCH 聚类的应用场景。

通过这次实验, 我对 K-means、AgglomerativeClustering 和 BIRCH 三种不同的聚类算法有了更深入的了解。尤其是通过实际应用这些算法到不同的数据集上, 我能够直观地观察到它们在不同情况下的表现和效果。

1. 关于 K-means 的收获:

- 我学会了如何调整 K-means 算法的关键参数, 例如簇的数量(`n_clusters`), 并理解了它对结果的影响。
- 我发现 K-means 算法在处理具有线性边界和均匀分布的数据集时表现最佳。
- 在实验中, K-means 算法对初始质心的选择十分敏感, 这可能导致结果的不稳定性。在实践中, 可能需要多次运行算法以确保结果的可靠性。

2. 关于 BIRCH 的收获:

- 我体会到了 BIRCH 算法在处理大规模数据集时的强大之处, 特别是当内存资源有限时。

- BIRCH 通过构建一个 CF 树（聚类特征树）并逐步精简信息来快速聚类，这一点对于初步探索数据非常有用。
- 在实验中，调整 BIRCH 的阈值和分支因子是一个挑战，但也是一个提升聚类质量的关键步骤。

3. 聚类算法的应用场景：

- K-means 适合于市场细分、社交网络分析、图像压缩等领域，尤其是那些数据集较为规整，簇之间边界清晰的场景。
- BIRCH 则更适用于需要快速处理大数据集的场景，比如实时数据流的分析和网络监控，或者是在资源受限的环境中进行初步的数据探索。

4. 个人体会：

- 实验不仅仅让我掌握了这些算法的理论知识，更重要的是通过实践提高了我运用这些算法解决实际问题的能力。
- 我意识到，无监督学习特别是聚类，是一种强大的数据分析工具，可以揭示数据中隐藏的模式和结构。
- 此外，我也体会到聚类分析在预处理数据、理解数据结构以及辅助监督学习等方面的重要作用。

总之，本次实验加深了我对聚类算法的理解，并让我意识到在不同的应用场景下选择合适的算法的重要性。我也学会了如何基于实验结果来评估和选择聚类算法，以便在未来的数据科学工作中应用。