



石河子大学信息科学与技术学院

〈数据挖掘〉课程实验报告

实验名称：	实验 6 支持向量机分类
学生姓名：	卢瑶
学 号：	20211018341
学 院：	信息科学与技术学院
专业年级：	计科 2021 级 5 班
指导教师：	刘雅辉
完成日期：	2024. 4. 23

实验六 支持向量机分类

一、实验目的

- 1、掌握支持向量机的分类原理。
- 2、掌握支持向量机分类算法的调参技巧和使用方法。

二、实验原理


支持向量机（Support Vector Machine, SVM）是一种对线性和非线性数据进行分类的方法。对于线性不可分的数据，SVM 通过引入核函数，将数据映射到较高维上变成线性可分。SVM 的基本模型是在特征空间上，利用支持向量和边缘找到最佳的分离超平面，使得正负样本之间的间隔最大。

三、实验环境


- 1、使用台湾大学林智仁教授等人开发的 LIBSVM。
下载网址：<https://www.csie.ntu.edu.tw/~cjlin/libsvm/>
可以选择 Java 版本或 Python 版本。
- 2、使用 scikit-learn 中的 SVM 算法
参考网址：<https://scikit-learn.org.cn/view/83.html>

四、实验数据

- 1、谣言数据集
rumor.txt
rumorunbalance.txt
- 2、线性可分和线性不可分数据集
linedata.txt



moons.txt:



五、实验要求

本次实验，利用 SVM 的线性、多项式以及核函数进行二分类，并比较他们在 rumor.txt 上的分类效果。

六、实验步骤和结果

6.1 实验代码

首先，我们编写实验代码如下所示：

```
1. import pandas as pd
2. from sklearn.model_selection import train_test_split
3. from sklearn.svm import SVC
4. from sklearn.metrics import classification_report, accuracy_score
5.
6. # 读取数据
7. df = pd.read_csv('/Users/luyao/Desktop/课内/DM/EX/实验六_分类实验-
   SVM/rumor.txt', sep='\t')
8.
9. # 准备数据
10. x, y = df.iloc[:, 0:12].values, df.iloc[:, 13].values
11. x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, ra
    ndom_state=0)
12.
13. # 线性 SVM
14. linear_svm = SVC(kernel='linear', cache_size=700, max_iter= 1000)
15. linear_svm.fit(x_train, y_train)
16. linear_predictions = linear_svm.predict(x_test)
17. linear_report = classification_report(y_test, linear_predictions)
18.
19. # 多项式 SVM
20. poly_svm = SVC(kernel='poly', degree=3, cache_size=700, max_iter=1000)
21. poly_svm.fit(x_train, y_train)
22. poly_predictions = poly_svm.predict(x_test)
23. poly_report = classification_report(y_test, poly_predictions)
24.
25. # # 核函数 SVM
26. rbf_svm = SVC(kernel='rbf', cache_size=700, max_iter= 1000)
27. rbf_svm.fit(x_train, y_train)
28. rbf_predictions = rbf_svm.predict(x_test)
29. rbf_report = classification_report(y_test, rbf_predictions)
30.
31. # 输出分类效果
32. print("线性 SVM 分类报告:\n", linear_report)
33. print("多项式 SVM 分类报告:\n", poly_report)
```

```
34.print("核函数 SVM 分类报告:\n", rbf_report)
```

6.2 线性 SVM 分类结果

线性SVM分类报告:

	precision	recall	f1-score	support
no	0.60	0.21	0.31	102
yes	0.51	0.86	0.64	98
accuracy			0.53	200
macro avg	0.55	0.53	0.47	200
weighted avg	0.56	0.53	0.47	200

图 1 线性 SVM 分类结果图

6.3 多项式 SVM 分类结果

多项式SVM分类报告:

	precision	recall	f1-score	support
no	1.00	0.01	0.02	102
yes	0.49	1.00	0.66	98
accuracy			0.49	200
macro avg	0.75	0.50	0.34	200
weighted avg	0.75	0.49	0.33	200

图 2 多项式 SVM 分类结果图

6.4 核函数 SVM 分类结果

核函数SVM分类报告：

	precision	recall	f1-score	support
no	0.57	0.35	0.44	102
yes	0.52	0.72	0.60	98
accuracy			0.54	200
macro avg	0.54	0.54	0.52	200
weighted avg	0.55	0.54	0.52	200

图 3 核函数 SVM 分类结果

七、实验结果分析

1. 线性 SVM

- **精确度(Precision):** 对于标记为"yes"的类，精确度为 0.51，意味着 51%被模型预测为"yes"的样本实际上是"yes"。
- **召回率(Recall):** 对于"yes"类，召回率为 0.86，表明模型能识别出 86%的实际"yes"样本。
- **F1 分数:** "yes"的 F1 分数为 0.64，较高的 F1 分数表明精确度和召回率的较好平衡。
- **总体表现:** 准确率为 53%，说明总体上模型的表现一般。

2. 多项式 SVM

- **精确度(Precision):** "yes"的精确度为 0.49，稍低，表明较多非"yes"样本被误分类为"yes"。
- **召回率(Recall):** "yes"的召回率为 1.00，说明模型能找出所有实际为"yes"的样本，但是精确度较低，伴随着较高的误报。
- **F1 分数:** "yes"的 F1 为 0.66，尽管召回率高，但低精确度限制了 F1 分数的提高。
- **总体表现:** 准确率为 49%，在所有模型中是最低的，主要是由于精确度较低。

3. 核函数 SVM (RBF)

- **精确度(Precision):** 对"yes"的精确度为 0.52，与线性 SVM 相似。
- **召回率(Recall):** "yes"的召回率为 0.72，比线性 SVM 低，但比多项式 SVM 更平衡。
- **F1 分数:** "yes"的 F1 为 0.60，显示出相对较好的精确度和召回率平衡。
- **总体表现:** 准确率为 54%，在三个模型中是最高的，显示出相对较好的性能平衡。

4. 结论

- **多项式 SVM** 由于其极高的召回率和极低的精确度，可能存在过拟合的问题，特别是当 degree 较高时容易出现这种情况。它捕捉到了所有的正类，但同时也错误地将大量负类判断为正类。

- **线性 SVM 和 RBF SVM** 表现相近，但 RBF SVM 在召回率和 F1 分数上略有优势，可能是因为它能更好地捕捉数据中的非线性关系。

八、本次实验的主要收获和体会，使用 SVM 分类的好处及其应用前景。

通过这次实验，我获得了丰富的理论和实践知识。以下是我的一些主要收获：

1. **理论与实践结合：**通过实际编写代码并应用 SVM 进行分类，我更深入地理解了支持向量机的工作原理。这个过程帮助我将抽象的理论知识转化为具体的操作技能。
2. **算法调优体会：**实验中的参数调整教会了我算法优化的重要性。通过调整不同的核函数和参数，我学会了如何改进模型的性能。
3. **数据处理的重要性：**为了提高 SVM 的性能，我意识到数据预处理的重要性，包括特征选择和数据清洗，这对于提高模型准确度至关重要。
4. **模型选择的思考：**我理解到没有一种模型是万能的。对于不同的数据集和任务，线性 SVM、多项式 SVM 和核函数 SVM 各有千秋。选择合适的模型对于实现最佳性能非常关键。
5. **实践中的问题解决：**在实验过程中遇到的问题如过拟合、模型选择等，促使我学会了如何诊断问题并寻找解决方案。

使用 SVM 分类的好处包括：

- **高效性：**SVM 尤其在高维数据中表现出色，这是由于其决策功能依赖于支持向量，而不是整个数据集。
- **多功能性：**通过简单地更换核函数，SVM 可以轻松地应用于线性和非线性问题。
- **泛化能力：**SVM 的最大化边际方法提供了良好的泛化能力，这意味着它对未知数据的预测准确率较高。

应用前景：

- **文本和超文本分类：**SVM 由于其泛化能力强和高效性，在文本分类问题上有巨大的应用潜力。
- **图像识别：**SVM 可以用于图像处理领域，特别是在特征提取后对图像内容进行分类。
- **生物和其他科学：**在基因分类和蛋白质分类中，SVM 的应用正逐步增加，其能力在处理复杂模式方面显示出极大潜力。
- **语音识别：**SVM 也被用于语音识别领域，它能够处理大量可能的输入组合。

在未来，随着技术的发展，我预计 SVM 将会与深度学习等其他机器学习方法结合，以解决更为复杂的问题，并在各种实际应用中发挥更大的作用。同时，我也期待着机器学习在云计算、边缘计算等新兴领域中的应用，这些都将为 SVM 打开新的应用前景。